Meylin Gutiérrez Montoya

RUIDO Y TRÁFICO EN BILBAO

Sistemas de Big Data

ÍNDICE

ÍNDICE **1**
INTRODUCCIÓN **2**
FASE 1: ADQUISICIÓN E INTEGRACIÓN DE DATOS **3**
1. Fuentes de Datos 3
2. Estrategia de Ingesta Automatizada 3
3. Integración y Coherencia de los Datos 4
FASE 2: CONSTRUCCIÓN DEL DATASET Y CALIDAD DEL DATO **5**
1. 1.Gestión de Valores Faltantes (Nulos) 5
2. 2.Tratamiento de Anomalías y Outliers 5
3. Tipado y Normalización 6
4. Estructura del Dataset Final 6
FASE 3: ANÁLISIS EXPLORATORIO Y EXTRACCIÓN DE CONOCIMIENTO (R) **8**
Metodología de Análisis 8
Resultados del Análisis 8
A) Análisis por Zonas: Identificación de Puntos Críticos 8
B) Análisis Temporal: Comportamiento por Franjas Horarias 9
C) Análisis Temporal: Laborable vs. Fin de Semana 9
D) Análisis de Comportamiento: Persistencia vs. Variabilidad 11
FASE 4: CUADRO DE MANDO (POWER BI) **13**
1. Modelado de Datos: Esquema en Estrella 13
2. Medidas DAX 13
Conclusiones y Recomendaciones 15
CONCLUSIONES **16**
Diagnóstico de la Situación Acústica 16
Zonas de Contraste 16
Propuestas de Mejora y Acción (Impacto) 16

INTRODUCCIÓN

El proyecto, titulado **"Ruido urbano en Bilbao y relación con el tráfico"**, tiene como objetivo principal realizar un análisis integral de la contaminación acústica en la ciudad utilizando datos reales.

Vivimos en entornos urbanos donde el ruido es una preocupación constante. Por ello, este trabajo busca no solo visualizar los niveles de decibelios en diferentes zonas, sino entender sus causas, explorando específicamente si existe una relación directa entre el tráfico rodado y el ruido registrado por la red de sonómetros del Ayuntamiento .

Para resolver este reto, he seguido un flujo de trabajo de Big Data que abarca desde la adquisición de los datos hasta su visualización final:

1. **Adquisición e Integración:** He conectado con las fuentes de datos abiertos (Open Data) del Ayuntamiento de Bilbao para obtener información sobre mediciones de ruido, ubicación de sonómetros y estado del tráfico.

2. **Procesamiento y Calidad:** Utilizando el lenguaje **R**, he realizado la limpieza y estructuración de los datos para asegurar que sean fiables y coherentes.

3. **Visualización y Análisis:** Finalmente, he construido un cuadro de mando interactivo en **Power BI** que permite explorar los datos temporal y geográficamente, facilitando la extracción de conclusiones.

A lo largo de esta documentación, detallaré las decisiones técnicas que he tomado, los problemas que he encontrado durante el procesamiento de los datos y las conclusiones a las que he llegado tras analizar la información.

FASE 1: ADQUISICIÓN E INTEGRACIÓN DE DATOS

En esta fase, el objetivo principal ha sido establecer una conexión automática con las fuentes de datos del Ayuntamiento de Bilbao y unificarlas en un único conjunto de datos coherente.

1. Fuentes de Datos

He trabajado con tres fuentes de datos abiertas, combinando formatos estándar JSON y GeoJSON:

a. **Sonómetros (Mediciones):** Fichero en formato **JSON** que proporciona los niveles de ruido (decibelios) en tiempo real.
b. **Sonómetros (Ubicación):** Fichero **GeoJSON** que contiene las coordenadas geográficas (latitud y longitud) y metadatos de los sensores.
c. **Tráfico en tiempo real:** Fichero **GeoJSON** con información sobre la intensidad, ocupación y velocidad de los vehículos en los tramos de carretera de la ciudad.

2. Estrategia de Ingesta Automatizada

Para garantizar la reproducibilidad del proyecto, he evitado las descargas manuales. En su lugar, he desarrollado scripts en R que conectan directamente con las APIs del Ayuntamiento.

I. **Librerías utilizadas:** He empleado jsonlite y httr2 para la gestión de las peticiones web y el parseo de los archivos JSON. Además, he creado un archivo utils.R para modularizar el código, guardando allí funciones reutilizables de descarga y carga de librerías.
II. **Generación de Histórico de Tráfico (Punto Crítico):** Detecté que la API de tráfico solo ofrece datos del momento actual . Para poder analizar la evolución temporal, desarrollé un script específico (*00_Descarga_trafico_historico.R*) que se ejecuta de forma iterativa (cada 20 minutos) durante varios días. Esto me ha permitido construir un dataset histórico robusto que no existía en la fuente original.

3. Integración y Coherencia de los Datos

El mayor reto técnico ha sido unir tres fuentes que no comparten una clave común directa. Para lograr una **integración consistente**, he abordado el problema desde dos dimensiones: espacial y temporal.

A) Coherencia Geográfica (Unión Espacial) Los sonómetros son "puntos" en el mapa, mientras que los datos de tráfico son "líneas" (tramos de calle). No existe una columna común "ID de calle" en ambas tablas. Para resolverlo, he utilizado la librería **sf (Simple Features)** para realizar una operación espacial:

1. He convertido las coordenadas de los sonómetros y los tramos de tráfico en objetos espaciales.
2. He aplicado la función st_nearest_feature, que calcula matemáticamente qué tramo de carretera está más cerca de cada sonómetro.
3. De esta forma, he asignado a cada sonómetro el CodigoSeccion de tráfico correspondiente.

B) Coherencia Temporal (Sincronización) Las mediciones de ruido y de tráfico ocurren en momentos distintos (ej. ruido a las 10:01 y tráfico a las 10:05). Para poder cruzarlos, he utilizado la librería lubridate:

1. He redondeado todas las marcas de tiempo a **bloques de 15 minutos** (creando la variable Clave_Tiempo).
2. Esto ha permitido agrupar las mediciones que ocurren en la misma ventana temporal.

Finalmente, he realizado un inner_join utilizando estas dos claves generadas (Ubicación espacial + Ventana temporal), obteniendo un dataset final integrado donde cada fila contiene el nivel de ruido y el estado del tráfico en ese lugar y momento exacto.

FASE 2: CONSTRUCCIÓN DEL DATASET Y CALIDAD DEL DATO

Una vez automatizada la descarga, el siguiente paso ha sido asegurar la calidad de la información. Los datos "crudos" suelen contener errores, formatos incorrectos o valores faltantes que pueden arruinar el análisis posterior.

1. **1.Gestión de Valores Faltantes (Nulos)**

Al explorar los datos con la función contar_nulos, detecté registros incompletos tanto en las mediciones de los sonómetros como en la ubicación de los mismos.

- **Decisión tomada:** He optado por eliminar los registros que contienen valores nulos (NA) utilizando la función drop_na (librería tidyr).
- **Justificación:** En este contexto, un dato incompleto carece de valor analítico. Si un sonómetro no tiene coordenada geográfica, no puedo ubicarlo en el mapa; si una medición no tiene fecha o decibelios, no sirve para el estudio temporal. Mantenerlos solo introduciría "ruido" en el modelo de datos.

2. **2.Tratamiento de Anomalías y Outliers**

He diferenciado entre "valores atípicos estadísticos" y "errores lógicos":

1. **Detección Estadística (IQR):** Implementé en utils.R una función propia llamada detectar_outliers_iqr basada en el **Rango Intercuartílico**. Esta función calcula los cuartiles (Q1 y Q3) y detecta valores que se alejan más de 1.5 veces del rango. Esto me permitió entender la distribución de los decibelios y la intensidad del tráfico, identificando picos de ruido extremos pero posibles.
2. **Eliminación de Errores Lógicos:** En el dataset de tráfico, detecté valores negativos en intensidad y ocupación (ej. -1), lo cual es físicamente imposible. Mediante un filtrado lógico en R, eliminé estos registros ya que corresponden a códigos de error de los sensores, asegurando que solo pasen al análisis datos válidos (>= 0).

3. Tipado y Normalización

Los datos originales venían mayoritariamente como texto (String). Para permitir cálculos matemáticos y de fechas, realicé las siguientes conversiones explícitas:

- **Fechas:** Uso de lubridate::ymd_hms y as.POSIXct para convertir las cadenas de texto en objetos de fecha reales.
- **Numéricos:** Conversión de decibelios, intensidad y coordenadas a numeric o integer.
- **Geográficos:** Transformación de las tablas a objetos espaciales sf (Simple Features) con el sistema de referencia de coordenadas **EPSG:4326** (WGS84), estándar para cartografía web.

4. Estructura del Dataset Final

El resultado de este proceso es un archivo único: dataset_final_bilbao.csv. Este dataset está **listo para el análisis (Business Intelligence)** y no requiere transformaciones complejas posteriores en Power BI.

El dataset cuenta con **2,741 registros** (filas) y **17 variables** (columnas), que se pueden clasificar en cuatro grupos de información:

A) Identificación y Ubicación del Sensor Estas columnas permiten situar el origen del dato en el mapa y agrupar por zonas.

- nombre_dispositivo: Identificador único del sonómetro (ej. *BI-RUI-C025*).
- address: Dirección textual donde está ubicado el sensor (ej. *Luis Briñas con Pozas*).
- latitude / longitude: Coordenadas geográficas limpias en formato decimal (WGS84), listas para ser arrastradas al objeto visual "Mapa" de Power BI.
- CodigoSeccion: Clave foránea que conecta la ubicación del sonómetro con el tramo de tráfico más cercano.

B) Mediciones de Ruido (Variable Objetivo)

- decibelios: Valor numérico (float) que representa la intensidad sonora registrada.
- fecha_medicion: Marca temporal exacta (datetime) de cuándo se tomó el dato.

C) Estado del Tráfico (Variables Explicativas) Gracias al cruce espacio-temporal, cada fila de ruido tiene asociado el estado del tráfico en ese preciso momento y lugar.

- Intensidad: Número de vehículos registrados.
- Ocupacion: Porcentaje de ocupación de la vía.
- Velocidad: Velocidad media en el tramo.

D) Claves de Sincronización

- Clave_Tiempo: Esta es una columna calculada crítica. Representa la fecha y hora redondeada a intervalos de 15 minutos. Actúa como la "columna pivote" que ha permitido unir el mundo del ruido con el mundo del tráfico, y será fundamental en Power BI para sincronizar los gráficos temporales.

FASE 3: ANÁLISIS EXPLORATORIO Y EXTRACCIÓN DE CONOCIMIENTO (R)

Una vez construido el dataset final, he llevado a cabo un análisis exploratorio en R para responder a las preguntas planteadas en el reto: ¿Dónde hay más ruido? ¿Cuándo ocurre? ¿Es culpa del tráfico?

Metodología de Análisis

Para esta fase, he utilizado principalmente la librería **ggplot2** (parte del ecosistema tidyverse), que permite construir gráficos por capas de forma flexible y profesional. El proceso ha seguido estos pasos:

1. **Agrupación:** Uso de group_by y summarise para calcular medias de ruido por sensor, hora y tipo de día.
2. **Visualización:** Creación de gráficos de barras, líneas temporales, dispersión (scatter plots) y diagramas de caja (boxplots).
3. **Interpretación:** Análisis visual de las tendencias para extraer conclusiones.

Resultados del Análisis

A) Análisis por Zonas: Identificación de Puntos Críticos

El objetivo es responder a la pregunta: ¿Qué lugares de Bilbao soportan, de media, los mayores niveles de contaminación acústica?

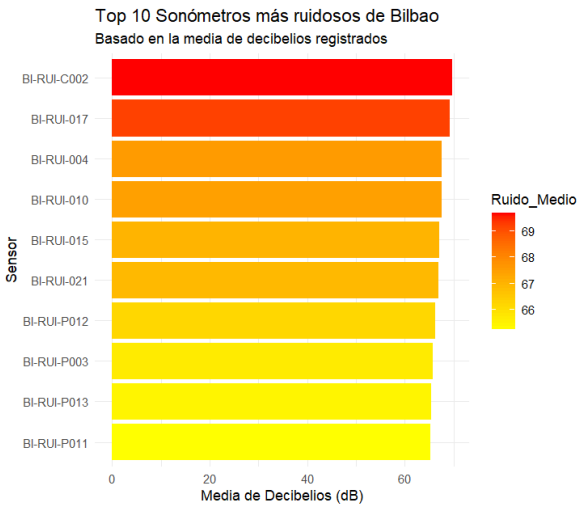

- **Interpretación:**
    1. Se observan diferencias significativas entre los distintos puntos de medición, lo que confirma que el ruido no es homogéneo en toda la ciudad.
    2. Los sensores que aparecen en la parte superior (en color rojo) indican calles o intersecciones donde el ruido es un problema persistente. Estos puntos probablemente coinciden con arterias de alto tráfico o zonas de ocio, lo que justifica la necesidad de medidas específicas en esas coordenadas.

B) Análisis Temporal: Comportamiento por Franjas Horarias

Este análisis busca entender cómo fluctúa la contaminación acústica a lo largo del día. El objetivo es confirmar si existen diferencias significativas entre la mañana, la tarde y la noche.

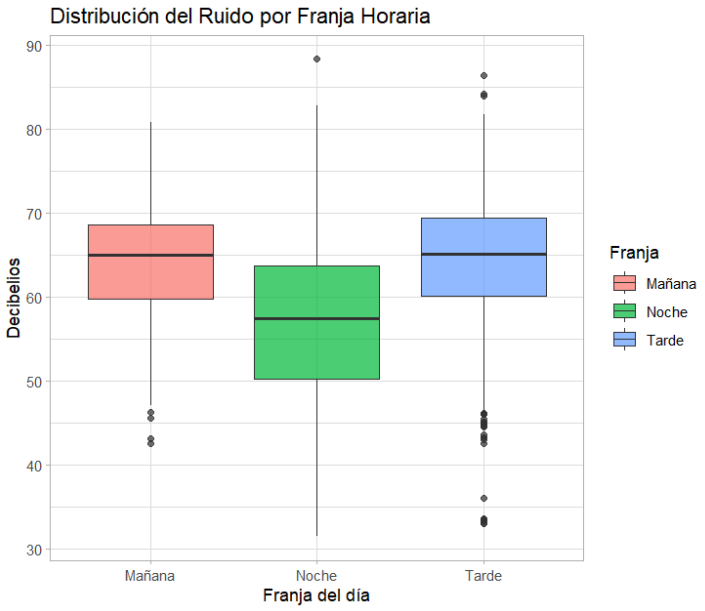

- **Interpretación:**

Diferencia Día/Noche: Como era de esperar, se observa una distinción clara. Las cajas correspondientes a las franjas diurnas (Mañana/Tarde) se sitúan notablemente más arriba en el eje Y que la franja nocturna. Con esto podemos decir que la actividad humana y el tráfico son los principales motores del ruido.

C) Análisis Temporal: Laborable vs. Fin de Semana

Con el anterior análisis concluimos que el ruido urbano está intrínsecamente ligado a la actividad humana. Este análisis tiene como objetivo visualizar cómo cambia la "huella

sonora" de la ciudad dependiendo de si es un día laborable (lunes a viernes) o un fin de semana/festivo.

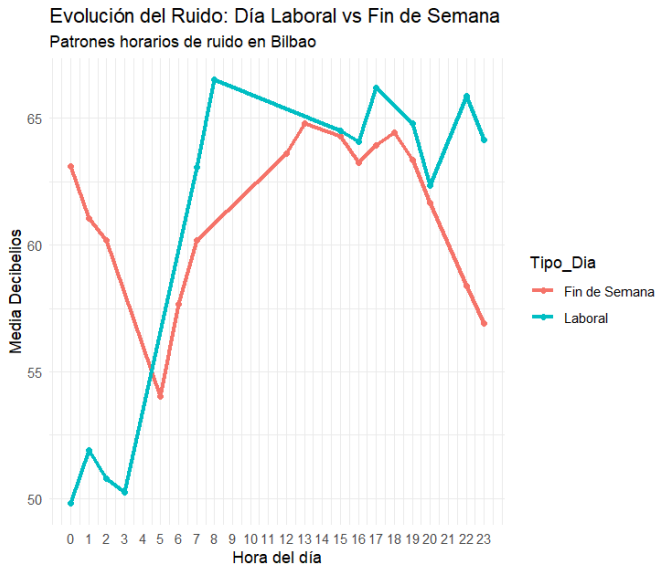

- **Interpretación:**

  El gráfico muestra un "desfase temporal" que refleja las rutinas de la ciudadanía:

  1. **El "Despertar" de la Ciudad:**
     - **Laborables:** La línea muestra un ascenso brusco y temprano (probablemente entre las 06:00 y las 08:00), coincidiendo con la entrada a colegios y trabajos.
     - **Fines de Semana:** La curva de ascenso es mucho más suave y tardía (comienza a subir sobre las 09:00 - 10:00), reflejando un inicio de jornada más relajado.
  2. **Intensidad Diurna:** Durante las horas centrales del día, la línea de los días laborables se mantiene generalmente por encima de la del fin de semana, debido a la carga comercial, logística y de tráfico rodado habitual.
  3. **Comportamiento Nocturno:** Es posible observar un comportamiento inverso durante la noche. Mientras que los días laborables el ruido cae en picado para el descanso, los fines de semana (especialmente viernes y sábado noche) la curva puede mantenerse alta hasta más tarde debido al ocio nocturno y la movilidad asociada.

D) Análisis de Comportamiento: Persistencia vs. Variabilidad

Saber el promedio de ruido no es suficiente; un promedio de 60dB puede deberse a un tráfico constante o a un silencio total interrumpido por un camión muy ruidoso. El objetivo de este análisis es distinguir entre:

- **Zonas de Ruido Persistente:** Lugares donde el ruido es un zumbido constante (ej. autopistas).
- **Zonas de Ruido Variable:** Lugares generalmente tranquilos pero con picos puntuales (ej. paso de ambulancias, carga y descarga).

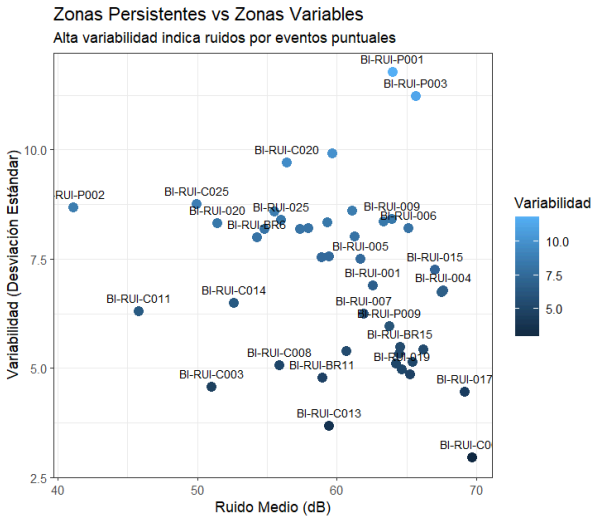

- **Interpretación:**

Este gráfico permite segmentar la ciudad en comportamientos diferenciados:

1. **Zonas Estables (Parte inferior del gráfico):** Los puntos que aparecen abajo tienen baja variabilidad. Si están a la derecha (media alta), indican un ruido constante y saturado, típico de vías rápidas donde el tráfico nunca cesa. Aquí las barreras acústicas serían efectivas.
2. **Zonas Inestables (Parte superior):** Los puntos altos indican que el ruido no es continuo, sino que se produce por "eventos". Aunque su media sea moderada, estos picos pueden ser muy molestos (ej. una calle tranquila donde de repente pasa un autobús ruidoso o hay actividad de carga/descarga).
3. **Identificación de Anomalías:** Gracias a las etiquetas, puedo detectar sensores específicos que se comportan de forma "rara" (muy variable), lo cual podría indicar

obras temporales, proximidad a servicios de emergencia (sirenas) o zonas de ocio nocturno con picos de actividad.

Conclusión del Análisis Exploratorio:

Hemos caracterizado el ruido en Bilbao no solo por "cuánto" (cantidad), sino por "cómo" (comportamiento). Hemos visto que el tráfico dicta el ritmo diario (Mañana/Tarde vs Noche) y que existen zonas críticas donde el ruido es estructural y constante, diferenciándolas de aquellas donde es puntual.

FASE 4: CUADRO DE MANDO (POWER BI)

Para la visualización final y la toma de decisiones, he importado el dataset procesado en **Microsoft PowerBI.** El objetivo ha sido construir un cuadro de mando interactivo que permita cruzar las variables de ruido y tráfico de forma dinámica.

1. **Modelado de Datos: Esquema en Estrella**

Este diseño separa los datos transaccionales de los descriptivos:

- **Tabla de Hechos (fac_mediciones):** Es la tabla central del modelo. Contiene los valores numéricos que queremos analizar (métricas) y las claves foráneas para conectar con las dimensiones.
- **Tablas de Dimensiones:**
    - **dim_fecha:** Tabla de calendario personalizada que permite el filtrado temporal inteligente.
    - **dim_sonometros:** Contiene los metadatos fijos de los sensores, como su nombre_dispositivo, dirección (address) y coordenadas geográficas (latitud, longitud).

2. **Medidas DAX**

Para asegurar la precisión de los cálculos y no depender de columnas calculadas que consumen memoria, he creado **Medidas Explícitas** utilizando lenguaje DAX.

Promedio de Ruido (Promedio_Ruido):

- *Fórmula:* Promedio_Ruido = AVERAGE(fac_mediciones[decibelios])
- *Explicación:* Esta es la métrica principal (KPI) del proyecto. Calcula el nivel medio de decibelios en función del contexto seleccionado. Al ser una medida, recalcula dinámicamente el valor si filtramos por "Noche" o por un barrio concreto.

Promedio de Intensidad de Tráfico (Promedio_Intensidad_Tráfico):

- *Fórmula:* Promedio_Intensidad_Tráfico = AVERAGE(fac_mediciones[Intensidad])
- *Explicación:* Calcula el volumen medio de vehículos. Su función principal en el dashboard es servir de comparativa: al superponerla en un gráfico con el *Promedio_Ruido*, permite confirmar visualmente si los picos de tráfico coinciden con los picos de ruido.

Promedio de Velocidad (Promedio_Velocidad):

- *Fórmula:* Promedio_Velocidad = AVERAGE(fac_mediciones[Velocidad])
- *Explicación:* Mide la velocidad media de circulación en los tramos estudiados. Esta variable añade profundidad al análisis, permitiendo investigar si el ruido se debe a la cantidad de coches (atascos) o a la velocidad de los mismos (ruido de motor/rodadura en vías rápidas).

DASHBOARD

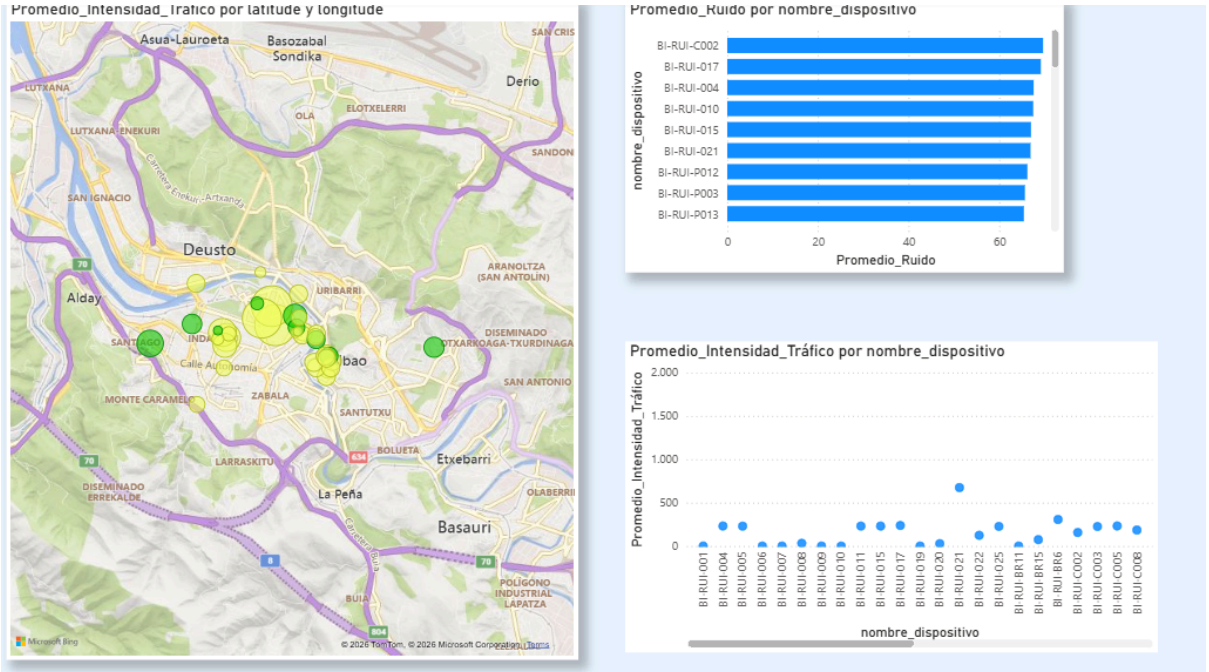

Se observan focos significativos en los accesos desde la autopista (cerca de San Mamés/Olabeaga) y en la zona de Deusto. Las burbujas verdes de menor tamaño en los extremos (como en Bolueta o hacia Artxanda) sugieren un tráfico más fluido o menos denso.

Según la OMS, niveles por encima de 65 dB durante el día se consideran ruidosos. Esto indica que las zonas monitorizadas están en el límite superior de confort acústico, probablemente debido a la actividad urbana y el tráfico constante.

Al buscar este dispositivo en la lista de ruido (punto 2), vemos que también está entre los que reportan mayor nivel sonoro, confirmando que es un punto crítico de congestión y contaminación acústica.

Conclusiones y Recomendaciones

1. **Zona de Intervención Prioritaria:** El área cubierta por el sensor BI-RUI-021 debería ser la primera en evaluarse para medidas de mitigación (peatonalización, radares de ruido o asfalto fonoabsorbente).
2. **Relación Tráfico-Ruido:** Existe una correlación visual clara: a mayor tamaño de burbuja en el centro del mapa, corresponden los niveles de ruido más altos en el gráfico de barras.
3. **Áreas de Alivio:** Las zonas con dispositivos como BI-RUI-001 o BI-RUI-006 muestran tráfico casi nulo en este promedio, lo que podría indicar calles residenciales o zonas de tráfico restringido.

CONCLUSIONES

Tras completar el flujo de trabajo de Big Data, desde la ingesta automatizada de fuentes abiertas hasta la visualización en Power BI, se presentan las siguientes conclusiones basadas en la evidencia de los datos:

Diagnóstico de la Situación Acústica

El análisis del cuadro de mando ha permitido confirmar la hipótesis inicial: **el tráfico rodado es el principal vector de contaminación acústica en Bilbao**.

- **Identificación de Puntos Negros:** El dashboard revela focos críticos en las arterias de acceso a la ciudad, específicamente en **San Mamés/Olabeaga** y la zona de **Deusto**.
- **Correlación Visual:** Existe una correspondencia directa entre la intensidad del tráfico y el ruido. En el mapa, las "burbujas" de mayor tamaño (alta congestión) coinciden sistemáticamente con los sensores que reportan niveles sonoros más altos en los gráficos de barras.
- **Alerta de Salud Pública:** Muchos de los puntos monitorizados operan en el límite superior del confort acústico definido por la **OMS (>65 dB)** durante el día. Esto sugiere que el ruido en estas zonas no es un evento puntual, sino una carga ambiental crónica derivada de la actividad urbana constante.

Zonas de Contraste

El modelo ha permitido segmentar la ciudad en dos realidades:

- **Áreas de Estrés Acústico:** Lideradas por el sensor **BI-RUI-021**, que se confirma como el punto más crítico tanto en congestión como en decibelios.
- **Áreas de Alivio:** Zonas periféricas o residenciales (como **Bolueta** o hacia **Artxanda**, y sensores como BI-RUI-001/006) muestran un tráfico casi nulo y niveles de ruido significativamente menores, actuando como pulmones acústicos de la ciudad.

Propuestas de Mejora y Acción (Impacto)

Basándonos en los datos procesados, se proponen las siguientes medidas de mitigación prioritaria:

1. **Intervención en el Foco BI-RUI-021:** Al ser la zona con peor desempeño combinado (Ruido + Tráfico), debería ser la prioridad número uno para acciones de urbanismo táctico, tales como la instalación de **asfalto fonoabsorbente** o la evaluación de radares de ruido.
2. **Gestión de Flujos:** Dado que los accesos desde la autopista son los más ruidosos, se podrían plantear medidas de calmado de tráfico (reducción de velocidad máxima) en esos tramos de transición hacia la ciudad